Синтаксический анализатор

Исходный код проекта представлен на GitHub в репозитории SyntaxDSLAnalyzer.

Построим синтаксический анализатор DSL для базы данных «Архив». Предполагается, что запросы к архиву формулируются в виде предложений на ограниченном естественном языке. Предложение всегда начинается с действия (глагола в повелительном наклонении), связанного с получением информации из архива. После действия указывается объект информации (документы, приказы или договоры), а также его название или номер. Дополнительно можно указать авторов документа или тему, источник, а также годы, за которые необходимо выполнить поиск. Уточняющие данные могут следовать в любом порядке.

Построим LL(1)-грамматику для описания запросов к архиву. Грамматика содержит также целые классы лексем, например <любой набор слов>, <сущ. в род. падеже>, <число>, <гл. в пов. наклонении>. Эти элементы проверяются на этапе морфологического анализа.

Грамматика имеет следующий вид:

<query> := <action><object><filters>

<action> := <гл. в пов. наклонении>

<object> := <objectType><objectName>

<objectType> := “документы” | “приказы” | “договоры”

<objectName> := <byTitle><byNumber>

<byTitle> := <titlePrep><titleName> | ε

<titlePrep> := “под названием”

<titleName> := “«”<любой набор слов>“»”<titleTail>

<titleTail> := “,”<titleName> | ε

<byNumber> := <numberPrep><numberBody> | ε

<numberPrep> := “по номеру”

<numberBody> := <число><numberTail>

<numberTail> := “,”<numberBody> | ε

<filters> := <filter><filters> | ε

<filter> := <author>| <theme>| <source>| <timeRange>

<author> := “от” <authorName>

<authorName> := <сущ. в род. падеже> <сущ. в род. падеже><authorTail>

<authorTail> := “,”<authorName> | ε

<theme> := <themePhrase><themeName>

<themePhrase> := “с темой”
<themeName> := <сущ.><themeTail>
<themeTail> := “,”<themeName> | ε
<source> := “из” <сущ. в род. падеже> <число>
<timeRange> := “за” <time>
<time> := <число><timeRangeTail>
<timeRangeTail> := “или”<time> | “год”

Код анализатора представлен в файле parser.py. Анализатор реализован в классе Parser и основывается на методе рекурсивного спуска. Данный метод предполагает создание рекурсивных процедур для каждого нетерминального символа грамматики. Каждый метод класса отвечает за разбор конкретного правила грамматики, при этом токены входного запроса последовательно обрабатываются слева направо. Для проверки грамматических характеристик слов (часть речи, падеж и наклонение глагола) используется библиотека pymorphy3. Для хранения результата синтаксического анализа используется класс Node. Каждый узел дерева содержит имя нетерминала или терминального символа (токена) и список дочерних узлов. Если входной запрос нарушает правила грамматики, генерируется исключение SyntaxError.

Примеры правильных запросов к архиву представлены на рисунке 1.

```
Исходный запрос:
Найди документы под названием «О правилах поведения в школе»
Синтаксический анализ: УСПЕХ

Исходный запрос:
Предоставь приказы от Андрея Кузьмина, Ивана Ивановича
Синтаксический анализ: УСПЕХ

Исходный запрос:
Выведи документы с темой безопасность, финансы
Синтаксический анализ: УСПЕХ

Исходный запрос:
Найди документы из министерства 5
Синтаксический анализ: УСПЕХ

Исходный запрос:
Найди документы за 2020 или 2021 год
Синтаксический анализ: УСПЕХ

Исходный запрос:
Найди документы под названием «Отчет» от Степана Сидорова за 2011 год с темой бизнес
Синтаксический анализ: УСПЕХ

Исходный запрос:
Покажи договоры от Демида Иванова за 2022 или 2023 год
Синтаксический анализ: УСПЕХ
```

Рисунок 1 - правильные запросы к базе данных “Архив”

Примеры некорректных запросов к архиву представлены на рисунке 2.

```
Исходный запрос:
Ищу документы
Синтаксический анализ: ОШИБКА
'ищу' не является глаголом в повелительном наклонении

Исходный запрос:
Найди приказы от андрей кузьмин
Синтаксический анализ: ОШИБКА
'андрей' должно быть существительным в родительном падеже

Исходный запрос:
Найди договоры по номеру abc
Синтаксический анализ: ОШИБКА
Ожидалось число

Исходный запрос:
Найди документы под названием «Отчет
Синтаксический анализ: ОШИБКА
Не закрыты кавычки

Исходный запрос:
Найди документы за год
Синтаксический анализ: ОШИБКА
Ожидался год (число)

Исходный запрос:
Найди документы из министерство
Синтаксический анализ: ОШИБКА
'министерство' должно быть существительным в родительном падеже

Исходный запрос:
Найди документы с темой 123
Синтаксический анализ: ОШИБКА
'123' должно быть существительным

Исходный запрос:
Найди документы по номеру
Синтаксический анализ: ОШИБКА
Ожидалось число
```

Рисунок 2 - некорректные запросы к базе данных “Архив”

Визуализация примеров работы анализатора при помощи библотеки graphviz представлена на рисунках 3-5.

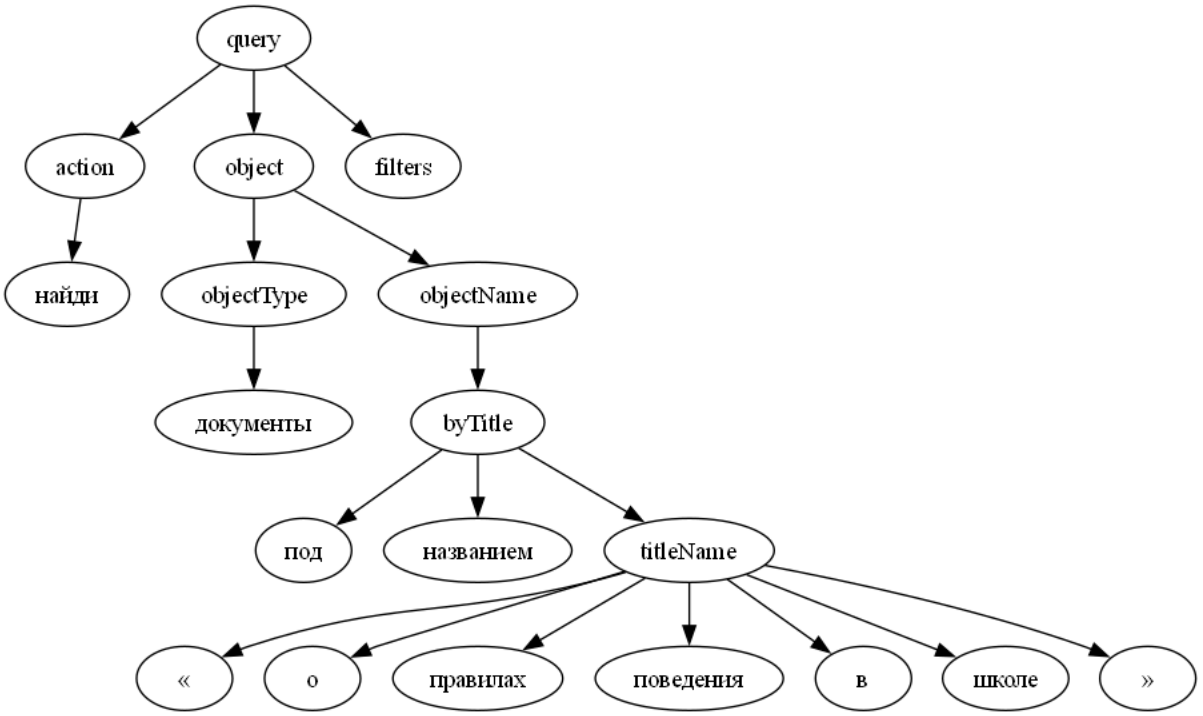

Рисунок 3 - Визуализация примера

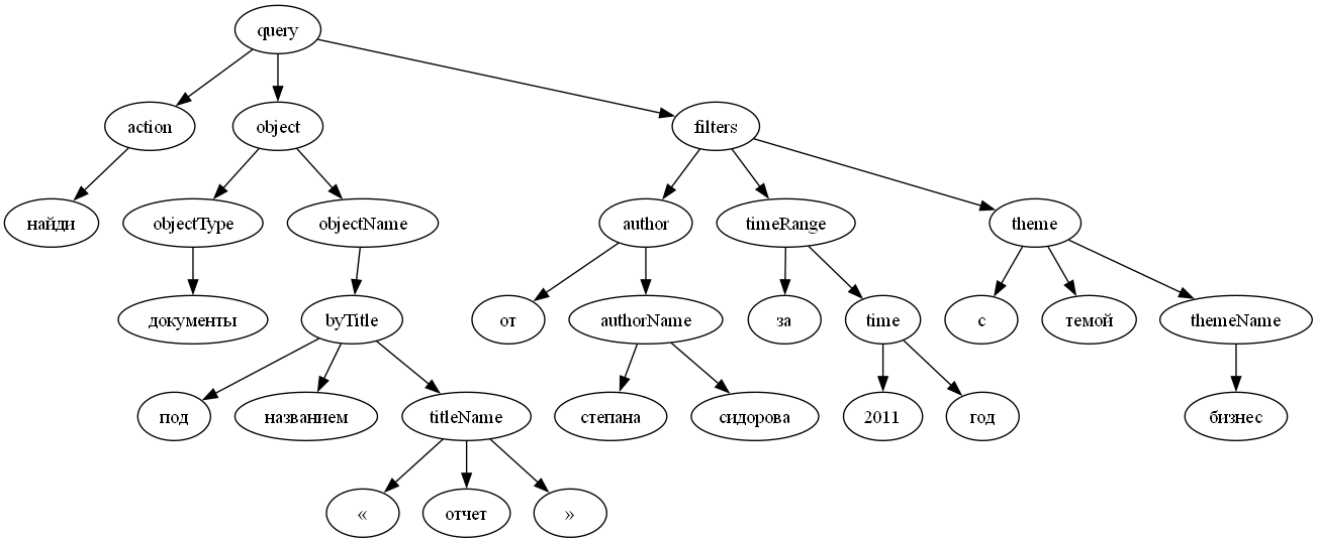

Рисунок 4 - Визуализация примера

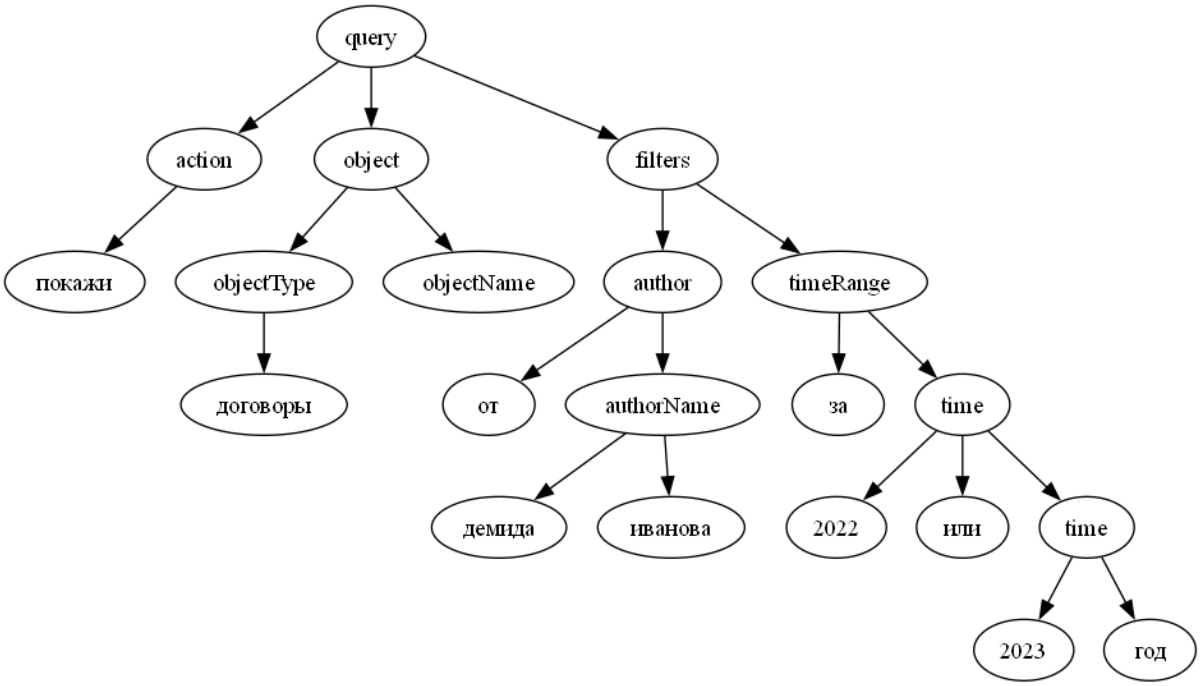

Рисунок 5 - Визуализация примера